# LU分解のブロック化と計算順序

寒川 光 日本アイ・ビー・エム (株)

数値解析の高速計算法は計算機システムの個性に依存する面が非常に強い。そこでこの問題を数値計算の分野だけからでなく、数値計算と計算機システム(コンパイラーと計算機構造)の両分野に跨がった視野から眺めてみたい。計算機ハードウェアの演算田路は年々高速化の一途を辿っているが、計算機の内部でのデータ移動にかかる時間は相対的に長くなっている。この計算機システムの動向を考えると、LU分解のような古典的なアルゴリズムに対しても、データ移動量を制御しやすい形のアルゴリズムに変形しておくことが重要である。データ移動量の制御は計算順序を変えることで達成されるので、LU分解においてどのような計算順序が可能がという問題を考える。

Blocking algorithms and computational ordering for LU decomposition

Hikaru Samukawa IBM Japan, Ltd. 18-24, Tsukiji 7-chome, Chuo-ku, Tokyo 104, Japan

Since the methods to perform numerical analysis in high-speed depend on the characteristics of computer systems, a discussion on this matter should be discussed not only from the view of numerical computation field but from the combined view of numerical computation field and computer systems field (compiler, architecture, hardware technology). Logic circuit becomes faster. On the other hand, time required to move data inside the computer becomes relatively slower than arithmetic computations. Considering this hardware trend, it is important to modify LU decomposition algorithms so that data transfer is easier to be controled. Since the data transfer control is achieved by selecting computational ordering, the possibilities of changing computational ordering are discussed.

#### 1.はじめに

数値計算の分野では新しいタイプの計算機が登場すると、既存のプログラムや アルゴリズムをその計算機の高速性能がひき出せる形に改訂する作業が行われる。 たとえばベクトル計算機が登場すると、建立(次方程式の直接解法のベクトル化 アルゴリズムが研究される。並列計算機しかり、ス・パースカラー計算機しかり である。計算機の種類は多く、しかもそれぞれが個性豊かなので、かウスの消去 法と呼ばれる古典的なアルゴリズムに対しても数多くりバリエーションが生み出 されて中くことになる。この現象を数値計算法の観点だけから眺めると何とを鬱 陶しく感じられるかもしれない。 問題の本質は、数値計算の分野と計算機システ ム(計算機構造とコンパイラー)の分野の間から出発している。さこでこの問題 を両分野を合わせた視野で眺め直し、将来登場するであろう新しいタイプの計算 機の塔載する技術を、数値計算アルゴリズムが受け入れるための技術を摸索する 立場で考えてみたい。

新レいタイプの計算機のために生み出された数値計算アルゴリズムのバリエー ションはいづれも.

- ・プログラムの文脈に「並行性」(演算を同時に実行しても良い性質)を追加 する
- ・計算機内部で発生する「データ移動量」を削減する

のスつの目標の一方(または両方)を狙っている。数値計算プログラムの計算時 間は乗算田粉を計算量の尺度とする方法が一般的であるが、その背景には初期の 計算機では乗算命令の実行時間が他の命令の実行時間に比べて非常に長かった、 という経緯がある。とくに乗算田路に Wallaceのアルゴリズムが導入される以前に は、東算命令の実行時間はビット長に比例して長くなった。この時代の計算機に おいては、記憶域のデータを 参照するため の時間は、倍精度の浮動小数点垂直に 比べれば無視しつるものだった。カウスの消去法の計算量がパシ/3 国の東加質で あり、計算時間が7つに比例すると見積ることはごく自然だったのである。しかし 最新の計算機ではこの事情はかなり異なっている。乗算囲路はサブミクロンのス ケールで微細加工された論理団路によって高速処理されるからである。しかもこ の囲路はパイプライン化され多重化される。一方、記憶域とプロセッサーの間は、 依然として ピンのついた銅線で結合されている。この物理的な大きさの 変化 が、 演算速度とデータ移動速度のバランスを変えてしまったのである。この計算機パ ードウェアの変化が、髙速計算のためのアルゴリズムに改訂を強いるのである。 すなわち、

プログラミング技法 \_\_ ハードウェア パイプライン化、多重化 演算速度とデータ移動速度の比 ― → 「データ移動量」の削減

となる。高速計算のために昔は計算量を削減したものであるが、現在は並行性を 付与することとデータ移動量を削減することを狙う場合の方が多くなっている。 簡単な例としてリバモアループを示す。このループは 960 囲の乗算と 960 囲の加 算を行うが、共通な演算をまとめることで、729 囲り乗算と 726 囲の加算に滅ら すことがざきる。

```
do i=/,/20

x(i) = u(i) + r*(z(i) + r*y(i))

+t*(u(i+3) + r*(u(i+2) + r*u(i+1))

+t*(u(i+6) + r*(u(i+5) + r*u(i+4))))

enddo
```

```
do i=2,124

Q(i)=Y*(U(i+1)+Y*U(i))

enddo

do i=2,124

b(i)=t*(U(i+1)+Q(i))

enddo

do i=1,120

X(i)=U(i)+Y*(Z(i)+Y*Y(i))


+b(i+1)+t*b(i+4)

enddo
```

この変形は古典的な計算機では効果をあげるが、RISCタイプのスーパースカラー計算機である IBMの RISC System/6000\*(RS/6000)では逆効果である(相当に遅くなる)。この理由は、データ移動量がストア命尽の増加で増えることと、東算と加算のチェイニングが断ち切られて単独で実行しなくてならない乗算と加算か現的れる(並行性を失なう)ことにある。

並行性は Fortran プログラムからも読みとることができるが、データ移動量は、レジスターとかキャッシュが Fortran プログラム(またはアーキテクチャー)から添烟たので押えたくい。 ちなり アングロウェッ

ら透週なので把えたくい。 右図に RS/6000 のハー ドウェア構成の一部を、データの流通の観点から 示した。RS/6000で用いられるPOWERアーキテクチ ャーは、算術演算命令のオペランドはすべてレジ スターとしている。 したがって レジスターに存在 するデータに対しては<u>海算命令だけ</u>ので計算でき るが、レジスターになければ<u>ロード命令と演革命</u> 食のを実行しなくてはならない。 ロード命令の実 行に際しては、アクセスされるデータがキャッシ ュに残っていないとキャッシュミスを発生して、 実記債装置からキャッシュへのステージングと呼 ばれる複雑な処理を伴なってレジスターヘロード <u>される</u>。このように参照されるデータがどこにあ るかということがデータ移動量を左右する。同じ 計算量であっても、演算器に近いところに残って いるデータで計算が進められるような計算順序に



することで、計算時間を短縮できる。行列計算のように少数の比較的単純な実行文でループが構成されるプログラムでは、レジスターへのデータ移動量はループの構成順序で、キャッシュへのデータ移動量はキャッシュブロック化と呼ばれる小行列を単位とする計算方法で制御することができるひ。どちらの方法も、「記憶域と演算器の間に一定の容量の作業域を設けたとき、作業域へのデータ移動量を最小化するような計算順序を送ぶ」ことと表現できる。なお、POWERアーキテクチャーは4オペランドの乗加算命令と32個の浮動小数点レジスターを定義しているので、レジスター群をひとつの作業域と考えやすい。

<sup>\*</sup> RISC System/6000 は IBM Corp. (米国)の商標である。

#### 2.LU分解におけるループの順序

行列行列積のプログラムではえれられる 3つの添字に関するループをどのような順序ででも構成可能である。すなわち、 右の下線部にはられる6つの組合せによる 36通りのプログラムが可能である。と と1日行列 Cの要素の位置(行と列)を Generic matrix-matrix multiplications do = 1, - do = 1, - do = 1, - C(i,j) = C(i,j) + A(i,k) \* b(k,j)

示すが、kは左辺には現めれない。本報告ではこれをテンソル数学にならって<u>ダミー添字(duminy index)</u>と呼ぶ。スカラー計算機でレジスターへのデータ移動量を少なくするのは、ダミー添字が最内側に用いられた時である。これはレジスターへの累加(accumulation)が達成されることで中間結果のストアが省けるからである。ベクトル・レジスター型のベクトル計算機においても、ベクトル命令の出力がベクトル・レジスターに累加できるルーで構成(外側ループ・ストリップマイニング)とした時、ベクトル・レジスターへのデータ移動量が少なくなる。

### 2.1 LU分解の式と計算順序の制約

LU分解の式を2通り示す。上は、この式に従って山の1行、しの1列、山の2行、いいの門に交互に計算すればクラウト分解になる式である。下は中間結果を意識した式で、よのループを外側に置いたまま内側にむとすのループを書けばガウスの消去法になる。

3つの添字i,j,kに関して、行列行列積のようなループ構成が可能がどうかを考えてみたい。行列行列積ではコンパイラーが6つの組合せから最適なものを選んでくれそうなぐらい単純で

 $\begin{cases} u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj} & \cdots (i \leq j \text{ o} \underbrace{e}_{k}) \\ l_{ij} = (a_{ij} - \sum_{k=1}^{j-1} l_{ik} u_{kj}) / u_{ij} \cdots (i > j \text{ o} \underbrace{e}_{k}) \end{cases}$ 

あったが、LU分解では、計算された要素(Uijやlij)がその後のステップで乗数として用いられるので複雑である。たとえば2行目の要素は

として計算されるが、次のステップ (k=2) では

$$Q_{ij}^{(2)} = Q_{ij}^{(1)} + Y_{i2} \cdot Q_{2j}^{(1)} \quad \left( = Q_{ij}^{(1)} + Y_{i2} \cdot \left( Q_{2j}^{(0)} + Y_{21} \cdot Q_{1j}^{(0)} \right) \right)$$

となる。下線の項  $a^{(i)}_{z_i}$  が  $a^{(o)}_{z_i}$  であってはならないのであるが、これは「下三角のi列の要素を計算する時は、上三角のi列の要素の計算が完了していなくてはならない」ことを意味している。上三角のi列の要素を計算する時も同様に、下三角のi列の計算が完了していなくてはならない。クラウト分解はこの計算順序の制約を端的に表わした計算順序になっている。

クラウト分解

## がウス消去法

## 2.2 IL-7°の順序 (loop ordering)

, LU分解a IL - プの順序を論文<sup>2)</sup>ざは Generic Gaussian elimination algorithm" と呼んで右のように記述し論じている。 ここでは行列行列積における6通りの - Generic Gaussian elimination do \_= \_ , \_ do \_= \_ , \_ do \_= \_ , \_ a(i,j) = a(i,j) - (a(i,k) \*a(k,j))/a(k,k)

ループ構成と同様の組合せが論じられている。しかしクラウト分解のように上三角の要素と下三角の母素を計算する時でループの順序が異なるものは、行列行列横のような6通りには入ってこない。そこで上三角のループの順序と下三角のループの順序を独立に扱えるようにしたい。クラウト分解をikk/jik型と、1/の前に上三角のループの順序を外側から、後に下三角のループの順序を外側から記述する。ガウスの消去法はkji/kji型となる。このように上下を独立に構成すると6×6=36通りの組合せが候補に上ってくる。

- i) 外側ループが上下ご一致するもの
  - i-i) 上三角、下三角が同じもの:6通り
  - 1-11) 上三角、下三角が異なるもの: 6通り

ixx/ixx, jxx/jxx, kxx/kxx

ii) 外側ループが上下で異なるもの: 4×6=24通り

ixx/ixx , ixx/kxx , kxx/ixx , ixx/ixx , ixx/kxx , kxx/ixx この中で前節で述べた計算順序の制約から 正しく計算できないものは下線を引いた 8通りである。上下独立にループ構成すると 28通りのプログラムができる。

Generic な表現だけ比べると行列行列積とLU分解は一見よく似ているので、言語仕様に行列がうまく取入れられればコンパイラーがあとはつまく最適化してくれるのではないか、との期待を抱きそうになる。しかしコンパイラーから見ると、行列行列積では両辺に現われる変数(C)は被加数でしかないが、LU分解では乗数、被乗数としても現われるし、またループ添字の動く範囲が外側のループ添字で記述されるという点で相当複雑になっている。このような理由で、たとえ行列(三角行列)がうまく言語仕様に組入れられても、計算順序の制約を適切な方法でコンパイラーに告げて、コンパイラーはそれから28通りのループの順序の組合せを比べて、対象となる計算機に最適なものを迷び出すのは難かしいように思う。

## 2.3 基本表換(elementary transformation)と計算順序

LU分解の複雑な消去のステップを基本変換行列  $R_k$ (対角要素が 1. で、  $\forall k$  列の k+1/n の  $\gamma_{ik}$  、それ以外の非対角要素が 0. )を用いて表わす。 L= 街行列 U は  $A^{(n-1)}=R_{n-1}R_{n-2}...R_{2}R_{1}A$  である。 ダミー添字 k は行列行列 積は総和の添字であるが、LU分解では(2つの Generic ta 表

現が類似しているにもかかわらず)、基本変換行列による累積の式により、Kは累積 (production accumulation) の添字であることがわかる。2.1節で例示した計算順序の 制約は、R,より先に RA を計算するものであった。

 $R_k$ の逆行列を $L_k$ とする。 $L_k$ は $R_k$ の非対角項の符号を反転して得られる。 $L_k$ には、添字kの小さいものを左側から掛けても、積の行列の個々の要素には積が現れれ

$$L_{1}L_{2}\cdots L_{n-1} = \begin{bmatrix} 1 \\ -Y_{21} & 1 \\ -Y_{31} - Y_{32} & 1 \\ \vdots & \vdots & \ddots \\ -Y_{n1} - Y_{n12} & \cdots & 1 \end{bmatrix} = L$$

$$\begin{bmatrix} 11 & 0 \\ L_{m \times m} & 0 \\ L_{(n-m) \times m} & L_{(n-m) \times (n-m)}^{22} \end{bmatrix}$$

ベクトルをāc=k のように記すことにする(小文字と でベクトル・c='は列、伝'は行を表わす)。 前鮮で挙げた33通りのループ構成を最外側ループの添字(内側2重ループのオペレーション)に着目して分類, 再考察したい。

(1) 先行消去型 (front elimination form)

kを最外側に用いた構成はループ添字の進行に対し消去計算が最も進行した( $R_k$ が決定した時点で $R_k$ を用いる計算をすべて完了する)形になる。内側2重ループはLのk列ベクトル( $\bar{L}_{C=k}$ )とLのk行ベクトル( $\bar{u}_{r=k}$ )を用いて右下小行列を消去するので、先行消去型と呼ぶことにする。

(2) 前進代入型 (forward substitution form)


ループ添字の進行に対して消去計算が最も遅れるのが、上三角のループの順序に立を最外側、下三角のループの順序に立を最外側に送んた構成である。上三角でうを最外側に用いた場合( $jxx/\cdots$ 型)を右に示した。内側2重ループはLの(j-1)×(j-1) の主小行列による前進代入になるので前進代入型と呼ぶことにする。下三角でえ最外側( $\cdots/ixx$ 型)とすると、U(i-1)x(i-1) による代入計算になる。

(3) 行列バクトル積型 (matrix-vector product form) ループ添字の進行が(1)と(2)の中間になるのが、下

前進代入型  $U_{c=j-1} = (L''_{(j-1)} \times (j-1))^{-1} \bar{\Delta}_{c=j-1}^{(0)}$ ただし  $\bar{\alpha}_{c=j-1}^{(0)}$  は Aの j 列ベク トルの上=角の要素(1~j 行)

1分のイクトル積型 doint = 2,n  $doint = a_{c-j} - L_{(n-j-1)\times(j-i)}^2 \overline{U}_{c-j}$  ただし  $\overline{a}_{c-j}^{(o)}$  は Aの f列 ベクトル の 下三角の要素(i+1 へれ 行)

三角のループの順序にまを最外側(…/ixx型)、上三角のループの順序にむを最外側(ixx/…型)に送んだ構成である。 内側2重ループ は行列ベクトル積和になるので行列ベクトル積型と呼ぶことにする。 下三角で i 最外側を図示した。上三角で i 最外側とすると 転置行列ベクトル積になる。



左に3つの型を示した。 内側2重ループで更新す 3部分(斜線)、参照する 部分(枠)、分解が完3し た部分(点)を示した。 先 行消去型で斜線部分は中 間結果などであるが、他 の型では分解が完了して いる。えとまは行列要素 の位置に対応する添字な ので、前進代入型と行列 ベクトル積型の違いは解 の得られる領域の違いに なる (三角形の辺上 か台形) の辺上に解が得られる)。 計算順序の制約は「先行


消去型と前進代入型を組合せられない」と言い換えられるが、これは両者(たとえば  $ixx/\cdots$ 型の図と  $ixx/\cdots$ であることから りかる。

現在LU分解アルゴリズムのバリエーションが種々の名称で呼ばれているが、筆者はこれらの名称が必ずしも適切ではないと感じている。たとえば iki/ki型を内積型と呼ぶ場合があるが、プログラムは kが最内側にないので最深のカーネル・ループは内積を計算するものではない。コンパイル技術の観点からを内積型は大量内積の構成を指すようである30。また、対称行列のLU分解(LDL<sup>t</sup>またはコレスキー分解)を考える時、上三角の行(i)と下三角の列(i)、上三角の列と下三角の行が対称の関係にあるので ik/jik型のように上下対称の型の変型とするのが考え易い。現在流行している呼称からはこれが内積型の変形なのかクラウト分解の変形なのか判然としない。上三角と下三角を分離して考えることと、数多くの計算順序のバリエーションに適切な名称を与えることは大切なことと考える。

## 2.4 軸選択と行要素交換 (pivot selection and swapping)

部分軸選択に伴なう行交換に2通りの方式がある。 K段の消去で選択された行と k行の要素を交換する方式を全列交換(FCS: Full Column

Swap)、Kvn列の母素だけを交換する方式を 部分列交換(PCS: Partial Column Swap) と呼ぶ ことにする。2つの方式の違いは連立1次方 程式AX=bの解を求めるための代入計算( Y= L'b, x= U-Y)でのベクトル要素の交換の タイミングの違いに関係する。FCSでは代入 に先立って右辺ベクトルの要素交換をまとめ



部分列交换(PCS)

て行えるが、PCSでは前進代入のループの中に折り込まなくてはならない。

#### LU分解のブロック化アルゴリズム

次数nの行列AをN×N個の小行列 {Azz} に 分割する(小行列の大きさは同じである必要は ないが、対角部分の小行列は正方とする)。 ブロック化されたLU分解の式を21節のLU分解 の2つの式に対応させて書くと右のようにな る。 ブロック化しない LU分解も サイズ 1×1 で ブロック化されたと考えると、 しょこし なの で、2.1節の式はブロック化の特殊た場合と見

$$\begin{cases} U_{IJ} = (L_{IJ})^{-1} (A_{IJ} - \sum_{K=1}^{J-1} L_{IK} U_{KJ}) \\ L_{IJ} = (U_{JJ})^{-1} (A_{IJ} - \sum_{K=1}^{J-1} L_{IK} U_{KJ}) \end{cases}$$

$$\begin{cases}
do \ K=1, N-1 \\
... \\
do \ J=K+1, N \\
... \\
do \ I=K+1, N
\end{cases}$$

$$A_{IJ}^{(K)} = A^{(K-1)} - L_{IK}U_{EJ}$$

做すこともできる。小行列に関する計算順序も、前草で述べたルールが当て飲ま り、I,J.Kに関する28通り(部分軸送状の場合20通り)が可容である。プロック化の 目的は記憶域→キャッシュ へのデータ移動量を減らすことができる点にある。れ がMで割り切れたとして、M行M列の小行列に分割された場合、この移動量はVm になる(iki/iki型とKJI/KJI型での比較)。

$$\frac{1}{m!} \stackrel{:}{\div} \left\{ \frac{1}{2} \sum_{k=1}^{n-1} (n-1+n-k-1) \cdot k \right\} / \left\{ \frac{1}{2} \sum_{K=1}^{n/m} (n-1+n-Km) \cdot Km \right\}$$

キャッシュを考えたブロック化には馴染みが無くても、行列が外部ファイルにあ 3時は行列を何らかの形でブロック化して入出力量を減らす工夫がなされる。 原 理的に両者は同じである。なお、部分軸送択を行う場合、ブロック内部ではFCS とする。PCSでは代入時( $U_{IJ}=(L_{IJ})^{-1}(A_{IJ}\cdots)$ )に行交換をループ内に入れなくては ならなく なるからである。

ブロック化の式は用途が広く、たとえばアンローリングによって2行2列を同 時に消去する場合、M=2としてブロック化の式を書くと計算順序を明確にできる。

#### 4. おわりに

髙速計算のアルゴリズムでは計算順序が重要である。計算順序を変更して並行 性を豊かにし、データ移動量を小なくするのがチューニングの主たる部分だから である。したがってコンパイルされ実行される段階迄計算順序を追求すべきである。

- 发考文献 -12. 寒川光:数値計算プログラミンクにおけるデータ移動制御のためのプロック化タルゴリズム, 情報処理学会論文誌、, Vol.33
- 2). Dongarra, J.J., et al.: Implementing Linear Algebra Algorithms ..., SIAM Review, Vol. 26, No.1 (1984)
- 3). 田中義一,岩澤京子:ベクトル計算機のためのコンパル技術,情報処理学会誌,Vol.31,No.6(1990)